
Cross-Modal Knowledge Distillation (Audio to Vision)

TRACCIA 5

OVERFITTONY

MARCO GIONFRIDDO

ANTONIO ROSANO

KEVIN SPERANZA

DEEP LEARNING - ADVANCED MODELS AND METHODS

A.A 2025/26

PROF. ANTONINO FURNARI

<https://github.com/johnfriddo/dl26-overfittony>

Perché l'audio da solo non basta?



L'audio è leggero, economico e perfetto per i dispositivi Edge (al contrario dei video che sono pesanti e costosi)...



...ma soffre di "**Modality Hallucination**". Senza il contesto visivo, suoni complessi o ambigui vengono spesso fraintesi dal modello.

L'ambiente di addestramento



EPIC-Kitchens (Video)

Il dominio ricco di contesto visivo.


Lo useremo per addestrare il nostro "esperto" (Teacher).




EPIC-Sounds (Audio)

Le tracce sonore.

Sarà l'unico input a disposizione del nostro modello finale in produzione (Baseline/Student).



La Baseline: classificare "al buio" con AST



Verso l'Edge: EfficientAT come alternativa Lightweight



Il limite


Il problema di AST: Alta accuratezza, ma eccessivo costo computazionale.

Soluzione: Transizione verso un modello progettato specificamente per l'Edge.




Le Scelte Implementative

1. Inizializzazione con pesi locali pre-addestrati.
2. Backbone totalmente congelato per preservare l'estrazione delle feature.
3. Applicazione della stessa pipeline di SpecAugment della baseline.




Risultati Audio-Only : Il trade-off tra Accuratezza e Risorse



Modello	Size (MB)	Inference (ms)	Accuratezza (mAP)
AST	328.98	619.50	~ 23%
EfficientAT	16.44	67.73	~ 14%

EPIC-KITCHENS & Limite Spazio di Archiviazione nel Cluster

Workflow



Confronto Dataset Originale con Subset

	Video Unici	Verbi Unici	Nomi Unici
Originale	495	97	289
Subset	172	90	235

Teacher Model 2D: ResNet

Panoramica

- **Backbone:** ResNet-50 (pre-addestramento ImageNet).
- **Output Multi-Head:** una testa per i Verbi una testa per i Nomi.
- **Loss:** Cross-Entropy Loss per ogni etichetta poi sommate (label-smoothing).

Single Frame (Baseline)

- 1 fotogramma (B, C, H, W).
- Nessuna fusione temporale.

Early Fusion

- 8 fotogrammi ($B, T \times C, H, W$).
- Fusione temporale immediata.

Late Fusion (with Pooling)

8 fotogrammi ($B \times T, C, H, W$).

Late Fusion (with FC Layers)

8 fotogrammi ($B \times T, C, H, W$).

Teacher Model 3D: SlowFast

Panoramica

- **Backbone:** SlowFast-R50 (pre-addestramento Kinetics-400).
- **Input:** Clip video a 32 fotogrammi (B, T, C, H, W).
- **Output Multi-Head:** una testa per i Verbi una testa per i Nomi.
- **Loss:** Cross-Entropy Loss per ogni etichetta poi sommate (label-smoothing).



Slow Pathway

- **Input :** 1 frame ogni α ($\alpha=4 \rightarrow$ 8 frame su 32)
- Analizza dettagli statici della scena, la texture e l'identità degli elementi.
- Ottimo per riconoscere i **nomi**.

Fast Pathway

- **Input:** Tutti i 32 frame della clip.
- Cattura il movimento fluido, la velocità e la dinamica temporale dell'azione.
- Ottimo per riconoscere i **verbi**.

Teacher: Risultati dell'Addestramento e Test sui Vari Modelli



Risultati sul Test Set

Modello	Top-1 Action	Top-1 Verb	Top-1 Noun
Single-Frame (T1)	~9.5%	~34.2%	~21.2%
Early Fusion (T8)	~8.5%	~33.9%	~16%
Late Fusion (with Pooling) (T8)	~15.4%	~39.4%	~29%
Late Fusion (with FC layers) (T8)	~14.3%	~42.1%	~22.9%
SlowFast (T32)	~20.6%	~50.3%	~32%

Prima di distillare bisogna allineare i dataset

Lo Student ha bisogno di coppie (**audio**, **video**) temporalmente coerenti durante il training. EPIC-Sounds e EPIC-Kitchens annotano gli stessi video ma con granularità incompatibile.

La pipeline è stata la seguente:

1 Join per video_id


EPIC-Sounds x EPIC-Kitchens ottenendo tutte le coppie candidate

2 Filtro temporale

Per ogni evento sonoro si calcola quanto è contenuto nell'azione video:

tempo_overlap / durata_audio.

Si tengono solo le coppie con valore ≥ 0.5 .




PROBLEMA: Il filtro riduce drasticamente i dati disponibili e non colpisce le classi in modo uniforme.

SPLIT	Baseline	Student	Perdita
Train	~48.000	~7.000	-85%
Val / Test	~13.000	~13.000	-0%

Scelta metodo: output incompatibili. allineiamo lo spazio latente

Il metodo classico (Vanilla KD) non è applicabile. allinea le distribuzioni di probabilità finali: il teacher produce logit su 97 verbi + 300 nomi, lo student deve classificare 44 classi audio. Non esiste mapping diretto

SOLUZIONE - FitNets (feature-based): invece di allineare gli output, allineiamo i vettori latenti intermedi. Il teacher e lo student producono entrambi un vettore di feature, indipendente dalle label finali. Un projector lineare impara a portare lo spazio audio in quello visivo.




$$\text{Total Loss} = \lambda \cdot \text{Task_Loss} + (1 - \lambda) \cdot \text{Distill_Loss}$$

$$\text{Distill Loss} = d(\text{Projector}(z_{\text{audio}}), z_{\text{video}})$$

Esperimenti: il metodo funziona, i dati non bastano

Settings: teacher ResNet-50 late pool T8, student AST con Cross Entropy



Exp	Best mAP
■ MSE Loss, Lambda=0.5	~17%
■ MSE Loss, Lambda=0.3	~16%
■ MSE Loss, Lambda=0.7	~16%
■ Cosine Loss, Lambda=0.5	~16%

Conclusioni, Limiti e Prossimi Passi

La distillazione cross-modale funziona, ma il vero limite è la scarsità di coppie audio-video allineate.

Il filtro temporale produce un subset cross-modale di EPIC-Sounds ridotto dell'85%, e il subset di EPIC-Kitchens utilizzato limita ulteriormente la varietà di scene che il teacher può trasferire. Il risultato è un mAP di 17% contro il 23% della baseline.



Teacher SlowFast

ResNet-50 su frame singoli è limitato: sostituirlo con SlowFast darebbe al teacher feature temporali più ricche, migliorando il segnale di distillazione.



Dataset completi


Usare EPIC-Kitchens completo eliminerebbe il sottoinsieme cross-modale ridotto, recuperando le coppie perse e riducendo l'abbattimento dell'85%.



Contrastive Loss

Sostituire FitNets con una contrastive distillation (InfoNCE): invece di allineare feature punto per punto, si impara a distinguere la coppia corretta da quelle negative nel batch.

Cross-Modal Knowledge Distillation (Audio to Vision)



Thanks for your attention

(it was the only we needed 🙏)

<https://github.com/johnfriddo/dl26-overfittony>